

Classificação Fuzzy: Método de Treinamento Wang-Mendel

Classificação

Um classificador é um algoritmo (sistema) que associa um rótulo de classe a um objeto com base na descrição deste objeto.

IF $X_1 = v_1^1$ AND $X_2 \geq v_2^1$ THEN class is 1
IF $X_1 \leq v_1^2$ AND $X_2 = v_2^2$ THEN class is 2
IF $X_1 = v_1^3$ AND $X_2 = v_2^3$ THEN class is 2
IF $X_1 \neq v_1^4$ AND $X_2 \leq v_2^4$ THEN class is 3

- É comum dizer que o classificador prediz o rótulo da classe.

Classificação

Um classificador é um algoritmo (sistema) que associa um rótulo de classe a um objeto com base na descrição deste objeto.

IF $X_1 = v_1^1$ AND $X_2 \geq v_2^1$ THEN class is 1
IF $X_1 \leq v_1^2$ AND $X_2 = v_2^2$ THEN class is 2
IF $X_1 = v_1^3$ AND $X_2 = v_2^3$ THEN class is 2
IF $X_1 \neq v_1^4$ AND $X_2 \leq v_2^4$ THEN class is 3

- É comum dizer que o classificador prediz o rótulo da classe.

Classificação: Crisp x Fuzzy

- Classificador tradicional:

IF $X_1 = v_1^1$ AND $X_2 \geq v_2^1$ THEN class is 1

IF $X_1 \leq v_1^2$ AND $X_2 = v_2^2$ THEN class is 3

IF $X_1 = v_1^3$ AND $X_2 = v_2^3$ THEN class is 2

- Classificadores fuzzy:

IF X_1 is medium AND X_2 is small THEN class is 1

IF X_1 is medium AND X_2 is large THEN class is 2

IF X_1 is large AND X_2 is small THEN class is 3

Classificação

Considerando como entrada um objeto-desconhecido(v_1, v_2) a classe deste objeto seria, por exemplo:

- classif. tradicional: classe 2, se $v_1 = v_1^3$ e $v_2 = v_2^3$
- classif. fuzzy: classe 1 com grau μ_1 e classe 2 com grau μ_2

Classificadores: Aprendizado Supervisionado

A construção de um procedimento de classificação a partir de um conjunto de dados para os quais a classe é conhecida recebe o nome de

reconhecimento de padrões,

discriminação,

aprendizado supervisionado de classificadores

(de forma a **distinguir** do processo de aprendizado não supervisionado ou **agrupamento** - clustering – casos para os quais a **classe não é conhecida a priori** e deve ser inferida a partir dos dados).

Classificador Fuzzy

A estrutura básica de um classificador fuzzy possui três componentes conceituais:

Base de dados (BD): Partição do Universo

Base de regras (BR): Conjunto de regras

Mecanismo de raciocínio: Inferência

Operadores (mais simples do que o SIF):

agregação de antecedentes

agregação das regras,


tomada de decisão (max ou max_soma).

Classificador Fuzzy: Aprendizado

Base de dados (BD): Partição do Universo


Base de regras (BR): Conjunto de regras

Mecanismo de raciocínio: Inferência




Partição Fuzzy do Universo


Diferentes métodos de partição



Grid



Árvore de Decisão





Agrupamento

Partição por Grid


A maior vantagem desta estratégia é a **simplicidade**.

O **especialista** fixa o **total**, **formato** e **localização** dos **conjuntos fuzzy**.

As **funções de pertinência** formam então um **grid** no espaço de entrada e o total de regras é função do total de conjuntos fuzzy.



Partição por Grid



Partição por Grid

Partição por grid:

Uniforme: usada quando o **especialista não possui conhecimento** sobre **regiões mais importantes** do espaço de entrada.

Não uniforme: usada quando o **especialista** ou um método automático de ajuste **foca o particionamento** em **regiões específicas** do espaço de entrada.


Partição por Grid

Partição por grid:


Uniforme: usada quando o **especialista não possui conhecimento** sobre **regiões mais importantes** do espaço de entrada.

Não uniforme: usada quando o **especialista** ou um método automático de ajuste **foca o particionamento** em **regiões específicas** do espaço de entrada.

Ajuste de partição:



Inicial(uniforme)



Final (Não-uniforme)

Partição por Árvores de Decisão

Partição por árvores de decisão:

Um método de partição por árvores de decisão bastante flexível é o fuzzy k-d-trees. Este método resulta de uma série de cortes de guilhotinas (corte que é feito ao longo de todo espaço a ser particionado) e cada região produzida é então submetida ao corte novamente.

Partição por Árvores de Decisão

Partição por árvores de decisão:

Um método de partição por árvores de decisão bastante flexível é o fuzzy k-d-trees. Este método resulta de uma série de cortes de guilhotinas (corte que é feito ao longo de todo espaço a ser particionado) e cada região produzida é então submetida ao corte novamente.

Em cada passo do algoritmo, algumas decisões devem ser tomadas:

- 1) qual a dimensão a ser cortada ?
- 2) em que posição realizar o corte.


Partição por Árvores de Decisão

Partição por árvores de decisão:

Um método de partição por árvores de decisão bastante flexível é o fuzzy k-d-trees. Este método resulta de uma série de cortes de guilhotinas (corte que é feito ao longo de todo espaço a ser particionado) e cada região produzida é então submetida ao corte novamente.

Em cada passo do algoritmo, algumas decisões devem ser tomadas:

- 1) qual a dimensão a ser cortada ?
- 2) em que posição realizar o corte.



Partição por Árvores de Decisão

Partição por árvores de decisão:

Um método de partição por árvores de decisão bastante flexível é o fuzzy k-d-trees. Este método resulta de uma série de cortes de guilhotinas (corte que é feito ao longo de todo espaço a ser particionado) e cada região produzida é então submetida ao corte novamente.

Em cada passo do algoritmo, algumas decisões devem ser tomadas:

- 1) qual a dimensão a ser cortada ?
- 2) em que posição realizar o corte.




Partição por Árvores de Decisão

Partição por árvores de decisão:

Um método de partição por árvores de decisão bastante flexível é o fuzzy k-d-trees. Este método resulta de uma série de cortes de guilhotinas (corte que é feito ao longo de todo espaço a ser particionado) e cada região produzida é então submetida ao corte novamente.

Em cada passo do algoritmo, algumas decisões devem ser tomadas:

- 1) qual a dimensão a ser cortada
- 2) em que posição realizar o corte.



Partição por Árvores de Decisão

Partição por árvores de decisão:

Um método de partição por árvores de decisão bastante flexível é o fuzzy k-d-trees. Este método resulta de uma série de cortes de guilhotinas (corte que é feito ao longo de todo espaço a ser particionado) e cada região produzida é então submetida ao corte novamente.

Em cada passo do algoritmo, algumas decisões devem ser tomadas:

- 1) qual a dimensão a ser cortada
- 2) em que posição realizar o corte. ?

Partição por Árvores de Decisão

Partição por árvores de decisão:

Um método de partição por árvores de decisão bastante flexível é o fuzzy k-d-trees. Este método resulta de uma série de cortes de guilhotinas (corte que é feito ao longo de todo espaço a ser particionado) e cada região produzida é então submetida ao corte novamente.

Em cada passo do algoritmo, algumas decisões devem ser tomadas:

- 1) qual a dimensão a ser cortada
- 2) em que posição realizar o corte. ?




Partição por Árvores de Decisão

Partição por árvores de decisão:

Um método de partição por árvores de decisão bastante flexível é o fuzzy k-d-trees. Este método resulta de uma série de cortes de guilhotinas (corte que é feito ao longo de todo espaço a ser particionado) e cada região produzida é então submetida ao corte novamente.

Em cada passo do algoritmo, algumas decisões devem ser tomadas:

- 1) qual a dimensão a ser cortada
- 2) em que posição realizar o corte. ?



Partição por Árvores de Decisão


Partição por árvores de decisão:

Um método de partição por árvores de decisão bastante flexível é o fuzzy k-d-trees. Este método resulta de uma série de cortes de guilhotinas (corte que é feito ao longo de todo espaço a ser particionado) e cada região produzida é então submetida ao corte novamente.

Em cada passo do algoritmo, algumas decisões devem ser tomadas:

- 1) qual a dimensão a ser cortada
- 2) em que posição realizar o corte.

Pto escolhido




Partição por Árvores de Decisão

Partição por árvores de decisão:

Um método de partição por árvores de decisão bastante flexível é o fuzzy k-d-trees. Este método resulta de uma série de cortes de guilhotinas (corte que é feito ao longo de todo espaço a ser particionado) e cada região produzida é então submetida ao corte novamente.

Em cada passo do algoritmo, algumas decisões devem ser tomadas:

- 1) qual a dimensão a ser cortada
- 2) em que posição realizar o corte.




Partição por Agrupamento

Partição por agrupamento (clustering partition):

As partições por agrupamento dividem os dados em vários grupos (clusters) tal que a similaridade dentro de um grupo é maior do que entre os grupos.

Partição por Agrupamento



Partição por Agrupamento

Existem diferentes métodos de agrupamento, entre os quais se destacam:

- Agrupamento hard-c-means (ou k-means);
- Agrupamento fuzzy-c-means (ou c-means).

Partição crisp : clustering – k-means

Algoritmo k-means:

Passo 1: Inicializar o centro do cluster

$\mathbf{c}_j, j = 1 \dots k$. Tipicamente, selecionam-se k pontos aleatoriamente entre todos pontos disponíveis.

Passo 2: Determina-se a matriz de pertinência

$U(n \times k)$ (eq. 2).

$$u_{ij} = \begin{cases} 1 & \text{se } \|\mathbf{x}_i - \mathbf{c}_i\|_2 \leq \|\mathbf{x}_i - \mathbf{c}_l\|_2, \text{ para cada } l \neq i \\ 0 & \text{caso contrário} \end{cases} \quad (\text{eq. 2})$$

Passo 3: Calcula-se a função custo J de acordo com (eq. 1). Parar se a função ficar abaixo de um certo limiar de tolerância ou se as melhorias em relação à iteração anterior ficarem abaixo de um certo limiar.

$$J = \sum_{i=1}^n \left(\sum_{j=1}^k \|\mathbf{x}_i - \mathbf{c}_j\|_2 \right) \quad (\text{eq. 1})$$

Passo 4: Atualizar os centros dos clusters de acordo com a (eq. 3) e ir para o passo 2.

$$\mathbf{c}_i = \frac{1}{|G_i|} \sum_{j, \mathbf{x}_j \in G_i} \mathbf{x}_j \quad (\text{eq. 3})$$

$$U = \begin{bmatrix} 1 & 0 & \dots & 0 \\ 0 & 0 & \dots & 1 \\ 0 & 1 & \dots & 0 \\ 1 & 0 & \dots & 0 \end{bmatrix}$$

Partição fuzzy : clustering - cmeans

Passo 1: Inicializar a matriz U com valores aleatórios em $[0, 1]$ tal que as restrições em (2b) sejam atendidas.

Passo 2: Calcular os centros dos fuzzy clusters \mathbf{c}_j , $j = 1 \dots c$. usando (eq 3b).

$$\mathbf{c}_j = \frac{\sum_{i=1}^n u_{ij}^m \mathbf{x}_i}{\sum_{i=1}^n u_{ij}^m}$$

Passo 3: Calcular a função de custo (eq 1b).
Condição de Parada: idêntica à do k-means.

$$J = \sum_{i=1}^n \left(\sum_{j=1}^c u_{ij}^m \|\mathbf{x}_i - \mathbf{c}_j\|_2 \right), \quad 1 < m < \infty$$

Passo 4: Calcular a nova matriz U usando a (eq. 4b). Ir para o passo 2.

$$u_{ij} = \frac{1}{\sum_{i=1}^n \left(\frac{d_{ij}}{d_{kj}} \right)^{2/(m-1)}}$$

A matriz U permite valores $u_{ij} \in [0, 1]$ com restrições:

$$\sum_{j=1}^k u_{ij} = 1, \forall i = 1, \dots, n \quad (\text{pto pode } \in \text{ a mais de um cluster})$$

$$0 < \sum_{j=1}^k \sum_{i=1}^n u_{ij} < n, \quad (\text{cada ponto } \in \text{ a pelo menos um cluster})$$

(eq 2b)

Classificador Fuzzy

Base de dados (BD): Partição do Universo (sobreposição entre os conjuntos)

Base de regras (BR): Conjunto de regras

Mecanismo de raciocínio: Inferência

TABELA 2. Classificação de conforto térmico em função das variáveis predictoras. **Thermal comfort rating according to the predicted variables.**

Regra	Temp. Superficial das Pernas	Temp. Superficial da Pele	Empenamento	Conforto Térmico (peso)
1	Alta	Alta	Alta	Perigo (1,0)
2	Alta	Alta	Média	Perigo (0,75)
3	Alta	Alta	Baixa	Perigo (0,5)
4	Alta	Média	Alta	Perigo (0,5)
5	Alta	Média	Média	Alerta (1,0)
6	Alta	Média	Baixa	Alerta (0,75)
7	Alta	Baixa	Alta	Alerta (0,75)
8	Alta	Baixa	Média	Alerta (0,5)
9	Alta	Baixa	Baixa	Conforto (0,5)
10	Média	Alta	Alta	Perigo (1,0)
11	Média	Alta	Média	Perigo (0,5)
12	Média	Alta	Baixa	Alerta (1,0)
13	Média	Média	Alta	Alerta (0,75)
14	Média	Média	Média	Conforto (0,5)
15	Média	Média	Baixa	Conforto (0,75)
16	Média	Baixa	Alta	Alerta (0,5)
17	Média	Baixa	Média	Conforto (0,75)
18	Média	Baixa	Baixa	Conforto (1,0)
19	Baixa	Alta	Alta	Alerta (1,0)
20	Baixa	Alta	Média	Alerta (0,75)
21	Baixa	Alta	Baixa	Alerta (0,5)
22	Baixa	Média	Alta	Conforto (0,75)
23	Baixa	Média	Média	Conforto (1,0)
24	Baixa	Média	Baixa	Conforto (0,75)
25	Baixa	Baixa	Alta	Conforto (1,0)
26	Baixa	Baixa	Média	Conforto (0,75)
27	Baixa	Baixa	Baixa	Conforto (0,5)

Classificador Fuzzy

Base de dados (BD): Partição do Universo (sobreposição entre os conjuntos)

Base de regras (BR): Conjunto de regras

Especialista

Automática

WangMendel
(mais simples)

Mecanismo de raciocínio: Inferência

Classificador Fuzzy

Base de dados (BD): Partição do Universo (grid ou c-means – há sobreposição)

Especialista

Base de regras (BR): Conjunto de regras

Automática

Mecanismo de raciocínio: Inferência

Operadores:


agregação de antecedentes (min ou produto)

agregação das regras (max),

tomada de decisão (max ou soma).

Método de Inferência

Dado um conjunto de teste S , consistindo de padrões (\mathbf{u}_s, y_s) , $s = 1, \dots, |S|$ onde $\mathbf{u}_s = (u_1, \dots, u_n)$ é o vetor de entradas e y_s é a saída.



Exemplo

$n=2$ (dimensões)

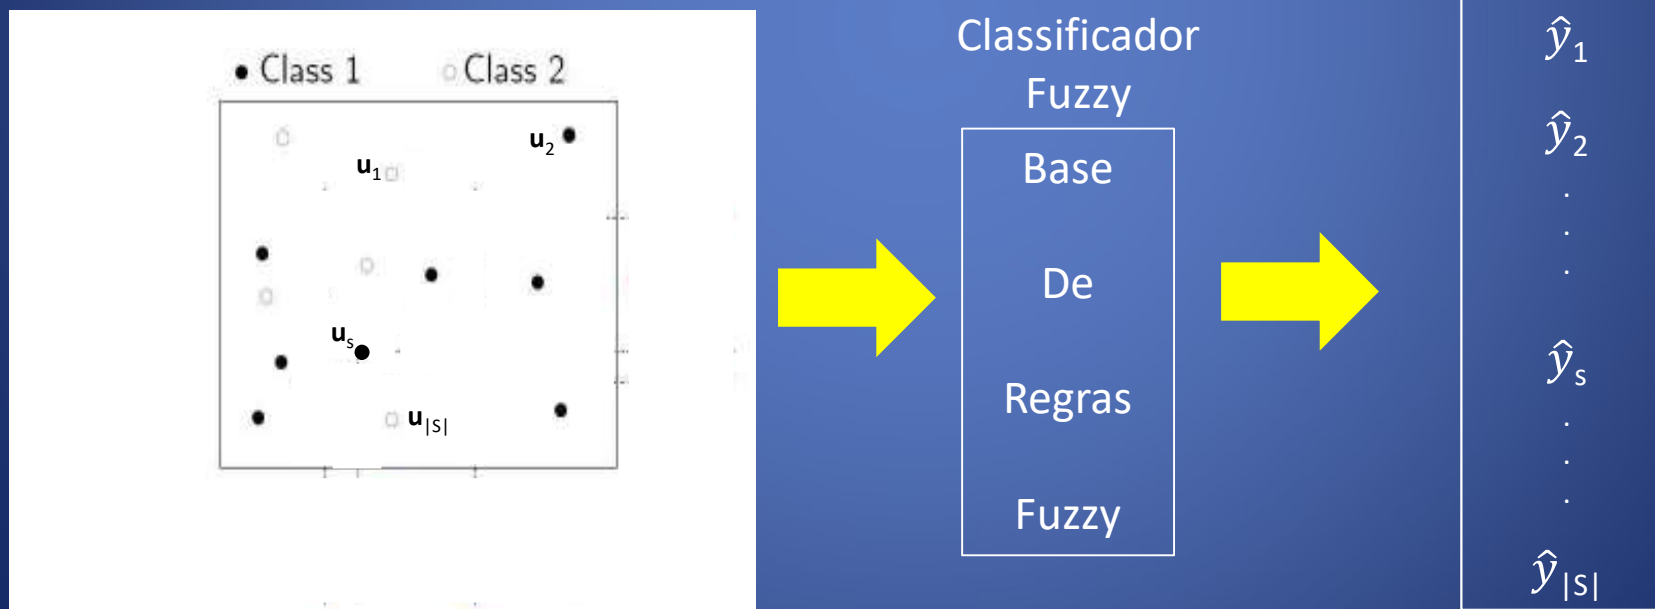
$|S|=12$ dados de teste

(\mathbf{u}_s, y_s) dado de teste

$y_s = \{\text{classe1}, \text{class2}\}$

Método de Inferência

Dado um conjunto de teste S , consistindo de padrões (\mathbf{u}_s, y_s) , $s = 1, \dots, |S|$ onde $\mathbf{u}_s = (u_1, \dots, u_n)$ é o vetor de entradas e y_s é a saída. Dada uma base de regras $RB = \{R^1, R^2, \dots, R^j, \dots, R^m\}$ obtida pelo método WM ou pelo especialista, onde R^j : If X_1 is A_1^j and X_2 is A_2^j and ... and X_n is A_n^j then y is B^j . Cada padrão é apresentado à base RB de forma a se obter uma saída inferida \hat{y}_s .





Método de Inferência

Dado um conjunto de teste S , consistindo de padrões (\mathbf{u}_s, y_s) , $s = 1, \dots, |S|$ onde $\mathbf{u}_s = (u_1, \dots, u_n)$ é o vetor de entradas e y_s é a saída. Dada uma base de regras $RB = \{R^1, R^2, \dots, R^j, \dots, R^m\}$ obtida pelo método WM ou pelo especialista, onde R^j : If X_1 is A_1^j and X_2 is A_2^j and ... and X_n is A_n^j then y is B^j . Cada padrão é apresentado à base RB de forma a se obter uma saída inferida \hat{y}_s . O primeiro passo consiste em se obter o matching da entrada $\mathbf{u}_s = (u_1, \dots, u_n)$ com a regra R^j . O matching da v -ésima variável do padrão de entrada s é dado por $\mu_{s_v}^j = \mu_{A_v^j}(u_v)$ onde $\mu_{A_v^j}(u_v)$ é o grau de pertinência para u_v na função de pertinência associada com o termo linguístico l_v definido para X_v na regra R^j . O segundo passo define o nível de disparo da regra a partir da apresentação do padrão de entrada ($\mu^j(\mathbf{u}_s) = \mu_{A_1^j}(u_1) \mathbf{t} \mu_{A_2^j}(u_2) \mathbf{t} \dots \mathbf{t} \mu_{A_n^j}(u_n)$), onde \mathbf{t} é uma t-norma (em geral produto ou mínimo). O terceiro passo consiste em se obter a saída inferida de cada regra (no caso do problema de classificação, consiste em se associar o nível de disparo com o label associado ao consequente (μ^j, B^j)). O quarto passo consiste em se agregar as saídas inferidas por cada regra formando a saída do sistema \hat{y}_s fuzzy baseado em RB . No caso do problema de classificação a classe inferida será dada por $\hat{y}_s = \arg \max_{B^j} (\mu^1, \mu^2, \dots, \mu^m)$, ou seja o label da regra que tem o maior nível de disparo. E este consiste no quinta e ultimo passo.

Inferência **Classificador Fuzzy** BD e BR Especialista

1) Matching das entradas com as regras




Método de Inferência

Dado um conjunto de teste S , consistindo de padrões (\mathbf{u}_s, y_s) , $s = 1, \dots, |S|$ onde $\mathbf{u}_s = (u_1, \dots, u_n)$ é o vetor de entradas e y_s é a saída. Dada uma base de regras $RB = \{R^1, R^2, \dots, R^j, \dots, R^m\}$ obtida pelo método WM ou pelo especialista, onde R^j : If X_1 is A_1^j and X_2 is A_2^j and ... and X_n is A_n^j then y is B^j . Cada padrão é apresentado à base RB de forma a se obter uma saída inferida \hat{y}_s . O primeiro passo consiste em se obter o matching da entrada $\mathbf{u}_s = (u_1, \dots, u_n)$ com a regra R^j . O matching da v -ésima variável do padrão de entrada s é dado por $\mu_{s_v}^j = \mu_{A_v^j}(u_v)$ onde $\mu_{A_v^j}(u_v)$ é o grau de pertinência para u_v na função de pertinência associada com o termo linguístico l_v definido para X_v na regra R^j . O segundo passo define o nível de disparo da regra a partir da apresentação do padrão de entrada $(\mu^j(\mathbf{u}_s) = \mu_{A_1^j}(u_1) \mathbf{t} \mu_{A_2^j}(u_2) \mathbf{t} \dots \mathbf{t} \mu_{A_n^j}(u_n))$, onde \mathbf{t} é uma t-norma (em geral produto ou mínimo). O terceiro passo consiste em se obter a saída inferida de cada regra (no caso do problema de classificação, consiste em se associar o nível de disparo com o label associado ao consequente (μ^j, B^j)). O quarto passo consiste em se agregar as saídas inferidas por cada regra formando a saída do sistema \hat{y}_s fuzzy baseado em RB . No caso do problema de classificação a classe inferida será dada por $\hat{y}_s = \arg \max_{B^j} (\mu^1, \mu^2, \dots, \mu^m)$, ou seja o label da regra que tem o maior nível de disparo. E este consiste no quinta e ultimo passo.

Inferência **Classificador Fuzzy** BD e BR Especialista


1) Matching das entradas com as regras

2) Cálculo do nível de disparo da regra



$$\mu_1 = \mu_{m_1}^1 \wedge \mu_{m_2}^1$$

$$\mu_2 = \mu_{m_1}^2 \wedge \mu_{m_2}^2$$




Método de Inferência

Dado um conjunto de teste S , consistindo de padrões (\mathbf{u}_s, y_s) , $s = 1, \dots, |S|$ onde $\mathbf{u}_s = (u_1, \dots, u_n)$ é o vetor de entradas e y_s é a saída. Dada uma base de regras $RB = \{R^1, R^2, \dots, R^j, \dots, R^m\}$ obtida pelo método WM ou pelo especialista, onde R^j : If X_1 is A_1^j and X_2 is A_2^j and ... and X_n is A_n^j then y is B^j . Cada padrão é apresentado à base RB de forma a se obter uma saída inferida \hat{y}_s . O primeiro passo consiste em se obter o matching da entrada $\mathbf{u}_s = (u_1, \dots, u_n)$ com a regra R^j . O matching da v -ésima variável do padrão de entrada s é dado por $\mu_{s_v}^j = \mu_{A_v^j}(u_v)$ onde $\mu_{A_v^j}(u_v)$ é o grau de pertinência para u_v na função de pertinência associada com o termo linguístico l_v definido para X_v na regra R^j . O segundo passo define o nível de disparo da regra a partir da apresentação do padrão de entrada $(\mu^j(\mathbf{u}_s) = \mu_{A_1^j}(u_1) \text{ t } \mu_{A_2^j}(u_2) \text{ t } \dots \text{ t } \mu_{A_n^j}(u_n))$, onde t é uma t-norma (em geral produto ou mínimo). O terceiro passo consiste em se obter a saída inferida de cada regra (no caso do problema de classificação, consiste em se associar o nível de disparo com o label associado ao consequente (μ^j, B^j)). O quarto passo consiste em se agregar as saídas inferidas por cada regra formando a saída do sistema \hat{y}_s fuzzy baseado em RB. No caso do problema de classificação a classe inferida será dada por $\hat{y}_s = \arg \max_{B^j} (\mu^1, \mu^2, \dots, \mu^m)$, ou seja o label da regra que tem o maior nível de disparo. E este consiste no quinta e ultimo passo.

Inferência **Classificador Fuzzy** BD e BR Especialista

1) Matching das entradas com as regras


2) Cálculo do nível de disparo da regra



$$\mu_1 = \mu_{m_1}^1 \wedge \mu_{m_2}^1$$

3) Saída Inferida pela regra

$$\mu_2 = \mu_{m_1}^2 \wedge \mu_{m_2}^2$$




Método de Inferência

Dado um conjunto de teste S , consistindo de padrões (\mathbf{u}_s, y_s) , $s = 1, \dots, |S|$ onde $\mathbf{u}_s = (u_1, \dots, u_n)$ é o vetor de entradas e y_s é a saída. Dada uma base de regras $RB = \{R^1, R^2, \dots, R^j, \dots, R^m\}$ obtida pelo método WM ou pelo especialista, onde R^j : If X_1 is A_1^j and X_2 is A_2^j and ... and X_n is A_n^j then y is B^j . Cada padrão é apresentado à base RB de forma a se obter uma saída inferida \hat{y}_s . O primeiro passo consiste em se obter o matching da entrada $\mathbf{u}_s = (u_1, \dots, u_n)$ com a regra R^j . O matching da v -ésima variável do padrão de entrada s é dado por $\mu_{s_v}^j = \mu_{A_v^j}(u_v)$ onde $\mu_{A_v^j}(u_v)$ é o grau de pertinência para u_v na função de pertinência associada com o termo linguístico l_v definido para X_v na regra R^j . O segundo passo define o nível de disparo da regra a partir da apresentação do padrão de entrada $(\mu^j(\mathbf{u}_s) = \mu_{A_1^j}(u_1) \text{ t } \mu_{A_2^j}(u_2) \text{ t } \dots \text{ t } \mu_{A_n^j}(u_n))$, onde t é uma t-norma (em geral produto ou mínimo). O terceiro passo consiste em se obter a saída inferida de cada regra (no caso do problema de classificação, consiste em se associar o nível de disparo com o label associado ao consequente (μ^j, B^j)). O quarto passo consiste em se agregar as saídas inferidas por cada regra formando a saída do sistema \hat{y}_s fuzzy baseado em RB. No caso do problema de classificação a classe inferida será dada por $\hat{y}_s = \arg \max_{B^j} (\mu^1, \mu^2, \dots, \mu^m)$, ou seja o label da regra que tem o maior nível de disparo. E este consiste no quinta e ultimo passo.

Inferência **Classificador Fuzzy** BD e BR Especialista

1) Matching das entradas com as regras

2) Cálculo do nível de disparo da regra




$$\mu_1 = \mu_{m_1}^1 \wedge \mu_{m_2}^1$$

3) Saída Inferida pela regra



4) Agregação das regras

$$\mu_2 = \mu_{m_1}^2 \wedge \mu_{m_2}^2$$




Método de Inferência

Dado um conjunto de teste S , consistindo de padrões (\mathbf{u}_s, y_s) , $s = 1, \dots, |S|$ onde $\mathbf{u}_s = (u_1, \dots, u_n)$ é o vetor de entradas e y_s é a saída. Dada uma base de regras $RB = \{R^1, R^2, \dots, R^j, \dots, R^m\}$ obtida pelo método WM ou pelo especialista, onde R^j : If X_1 is A_1^j and X_2 is A_2^j and ... and X_n is A_n^j then y is B^j . Cada padrão é apresentado à base RB de forma a se obter uma saída inferida \hat{y}_s . O primeiro passo consiste em se obter o matching da entrada $\mathbf{u}_s = (u_1, \dots, u_n)$ com a regra R^j . O matching da v -ésima variável do padrão de entrada s é dado por $\mu_{s_v}^j = \mu_{A_v^j}(u_v)$ onde $\mu_{A_v^j}(u_v)$ é o grau de pertinência para u_v na função de pertinência associada com o termo linguístico l_v definido para X_v na regra R^j . O segundo passo define o nível de disparo da regra a partir da apresentação do padrão de entrada $(\mu^j(\mathbf{u}_s) = \mu_{A_1^j}(u_1) \text{ t } \mu_{A_2^j}(u_2) \text{ t } \dots \text{ t } \mu_{A_n^j}(u_n))$, onde t é uma t-norma (em geral produto ou mínimo). O terceiro passo consiste em se obter a saída inferida de cada regra (no caso do problema de classificação, consiste em se associar o nível de disparo com o label associado ao consequente (μ^j, B^j)). O quarto passo consiste em se agregar as saídas inferidas por cada regra formando a saída do sistema \hat{y}_s fuzzy baseado em RB. No caso do problema de classificação a classe inferida será dada por $\hat{y}_s = \arg \max_{B^j} (\mu^1, \mu^2, \dots, \mu^m)$, ou seja o label da regra que tem o maior nível de disparo. E este consiste no quinta e ultimo passo.

Inferência **Classificador Fuzzy** BD e BR Especialista

1) Matching das entradas com as regras

2) Cálculo do nível de disparo da regra



$$\mu_1 = \mu_{m_1}^1 \wedge \mu_{m_2}^1$$



5) Tomada de decisão

3) Saída Inferida pela regra

Classe com Max μ

4) Agregação das regras

$$\mu_2 = \mu_{m_1}^2 \wedge \mu_{m_2}^2$$



Classificador Fuzzy

Base de dados (BD): Partição do Universo (grid ou c-means)

Base de regras (BR): Conjunto de regras

Especialista

Automática

Mecanismo de raciocínio: Inferência

Operadores:

agregação de antecedentes

agregação das regras,

tomada de decisão (max ou soma).

Definição Automática da BR


• Dados de Treinamento

x1	x2	x3	y
15,04	-0,12	-0,48	13,47
20,97	0,29	1,10	-22,24
-25,54	0,30	-1,72	53,74
4,73	0,32	-1,17	-19,74
17,82	0,68	1,06	-83,21
-15,69	-0,36	1,01	47,35
-6,68	-0,54	-0,98	49,82
-3,98	0,58	-1,27	6,60
9,93	0,21	-2,53	33,42
8,41	0,74	0,43	-43,88

Problema de aproximação


 • Método de Wang Mendel 

 (BR a partir dos dados)



Problema de classificação

x1	x2	Class
15,04	-0,12	1
20,97	0,29	1
-25,54	0,30	2
4,73	0,32	2
17,82	0,68	1
-15,69	-0,36	1
-6,68	-0,54	2
-3,98	0,58	2
9,93	0,21	2
8,41	0,74	1

Algoritmo de Wang Mendel

Método para geração de regras fuzzy a partir de dados de entrada-saída.


Passo1: Definir o número de termos linguísticos e particionar os universos de todas as variáveis de entrada.

Passo2: Criar uma regra fuzzy para cada elemento do conjunto de treino – para cada variável (atributo) selecionar a MF com maior grau de pertinência.


Passo 3: calcular o nível de disparo de todas as regras (função da norma-t dos níveis de ativação de cada antecedente).

Passo 4: Eliminar as redundâncias e inconsistências (regras com mesmo antecedente e consequente diferente) deixando apenas as regras com maior nível de disparo.

WM: Passo 1 – Partição Fuzzy




WM: Passo 1 – Partição Fuzzy



WM: Passo 2 – 1 regra p/ cada entrada de treino

x_p : class 1
 x_k : class 1
 x_m : class 2
 x_l : class 2



Regra p: Se x_1 é A^p_1 e x_2 é A^p_2 então classe é class1


Regra k: Se x_1 é A^k_1 e x_2 é A^k_2 então classe é class1

Regra m: Se x_1 é A^m_1 e x_2 é A^m_2 então classe é class2

x_l não gera
 Regra na
 Região
 $A^l_1 \times A^l_2$

WM: Passo 2 – 1 regra p/ cada entrada de treino

x_p : class 1
 x_k : class 1
 x_m : class 2
 x_l : class 2




Regra p: Se x_1 é A_1^i e x_2 é A_2^j então classe é **class1**

Regra k: Se x_1 é A_1^i e x_2 é A_2^j então classe é **class1**

Regra m: Se x_1 é A_1^i e x_2 é A_2^j então classe é **class2**

x_l não gera
 Regra na
 Região
 $A_1^i \times A_2^j$


WM: Passo 3 – Nível de disparo da regra



Regra p: Se x_1 é A_1^j e x_2 é A_2^j então classe é **class1**

Nível de disparo da regra p: $\mu(x_{1p}) \text{ t } \mu(x_{2p})$

WM: Passo 3 – Nível de disparo da regra



Regra p: Se x_1 é A_1^j e x_2 é A_2^j então classe é **class1**

Nível de disparo da regra p: $\mu(x_{1p}) \wedge \mu(x_{2p})$

WM: Passo 4 – elimina redundância e inconsistência nas regras (nível de disparo)

Regra p: Se x1 é A_1^j e x2 é A_2^j então classe é **class1**

Nível de disparo da regra: $FS_{Rp} = \mu(X_{1p}) \text{ t } \mu(X_{2p})$

Regra k: Se x1 é A_1^j e x2 é A_2^j então classe é **class1**

Nível de disparo da regra k: $FS_{Rk} = \mu(X_{1k}) \text{ t } \mu(X_{2k})$

Regra m: Se x1 é A_1^j e x2 é A_2^j então classe é **class2**

Nível de disparo da regra m: $FS_{Rm} = \mu(X_{1m}) \text{ t } \mu(X_{2m})$


Regras p e k são reduntantes (iguais) e ambas são inconsistentes com a regra m

Se $FS_{Rp} < FS_{Rk} < FS_{Rm}$ **Apenas a regra m permanece**

Regra m: Se x1 é A_1^j e x2 é A_2^j então classe é **class2**

Nível de disparo da regra m: $\mu(X_{1m}) \text{ t } \mu(X_{2m})$

WM: Passo 4 – elimina redundância e inconsistência nas regras (maioria)




Sumarizando: Método de Treinamento Wang-Mendel

1 Método de Wang-Mendel

Dado um conjunto de treinamento T , consistindo de pares (\mathbf{x}_t, y_t) , $t = 1, \dots, |T|$ onde $\mathbf{x}_t = (x_1, \dots, x_n)$ é o vetor de entradas y_t é a saída, uma regra R^t é criada para cada par (\mathbf{x}, y) , considerando a partição fuzzy para cada variável de entrada X_v , $v = 1, \dots, n$, onde L_v é o total de termos linguísticos na partição da variável X_v . O termo linguístico l_v^t escolhido para cada variável X_v na regra R^t é $l_v^t = \arg \max (\mu_{l_v}(x_v), l_v = 1, \dots, L_v)$, i.e. l_v^t é associado com a função de pertinência que tem o maior grau de pertinência para o ponto com coordenada x_v . Um base de regras inicial (chamada base completa) é gerada ($RB_{complete} = \{R^1, R^2, \dots, R^t, \dots, R^{|T|}\}$) agrupando todas as regras geradas pelos dados de treinamento. $RB_{complete}$ pode conter regras redundantes (iguais) e inconsistentes (mesmo antecedente e consequentes diferentes). Um base de regras final (base reduzida) RB_{reduc} é criada a partir de um processo de refinamento de $RB_{complete}$. Neste caso, apenas uma única regra é mantida para cada antecedente possível (premissa da regra) e seu consequente é escolhido tendo por base o nível de disparo (FS do inglês Firing Strength) ($FS^t = \mu_{l_1^t}(x_1) \text{ t } \mu_{l_2^t}(x_2) \text{ t } \dots \text{ t } \mu_{l_n^t}(x_n)$), onde t é uma t-norma (em geral produto ou mínimo) e $\mu_{l_v^t}(x_v)$ é o grau de pertinência para x_v na função de pertinência associada com o termo linguístico l_v escolhido para X_v na regra R^t . O consequente é tal que seu nível de disparo é o maior dentre todos os consequentes com mesmo antecedente (mesma premissa da regra).

Método de Wang Mendel

Dada um partição Fuzzy:




Para cada (\mathbf{x}_t, y_t) , com $\mathbf{x}_t = (x_{t1}, \dots, x_{tn}) \in T$,
 criar uma regra fuzzy com antec e conseq dados por:
 (antec = $\max_i MFi(X_k), k=1, \dots, n$, conseq = y_t);

Calcular nível de disparo (FS_{Rt}) para cada regra fuzzy criada;


Eliminar redundâncias e inconsistências

(Regra Final = $\max FS_{Rt}$ para toda regra de mesmo antec.


Classificador Fuzzy




$$\mu_1 = \mu_{m_1}^1 \wedge \mu_{m_2}^1 = FS_{R1}$$



$$\mu_2 = \mu_{m_1}^2 \wedge \mu_{m_2}^2 = FS_{R2}$$



Wang Mendel Method



Problema de Classificação

- 1) Para cada $x_t \in T$, criar uma regra fuzzy (antec = max MF);
- 2) Calcular nível de disparo (FS) para cada regra fuzzy criada;
- 3) Eliminar redundâncias e inconsistências (Regra Final = max FS).

R_p : If X_1 is A^p_1 and X_2 is A^p_2 then Y is Class 1
 R_k : If X_1 is A^k_1 and X_2 is A^k_2 then Y is Class 1
 R_m : If X_1 is A^m_1 and X_2 is A^m_2 then Y is Class 2

→ redundâncias
 → inconsistências


R_m : If X_1 is A^m_1 and X_2 is A^m_2 then Y is Class 2 regra final

Aplicação do Método WM


- Problema de Classificação
- Dados artificiais representando 3 classes

2 variáveis de entrada


- Instâncias mais separadas
- Instâncias mais próximas



(instância mais separada)





(instância mais próxima)



Resultado do Método de WM

If X1 is and X2 is		WM	
		then Class is	
		Instance a	Instance b
1	1	A	A
1	2	A	B
1	3	A	C
2	1	B	A
2	2	B	B
2	3	B	C
3	1	C	A
3	2	C	B
3	3	C	C



Aplicação do Método WM

- Problemas de Classificação (4 classes)

5 variáveis de entrada

STG (The degree of study time for goal object materials)

SCG (The degree of repetition number of user for goal object materials)

STR (The degree of study time of user for related objects with goal object)

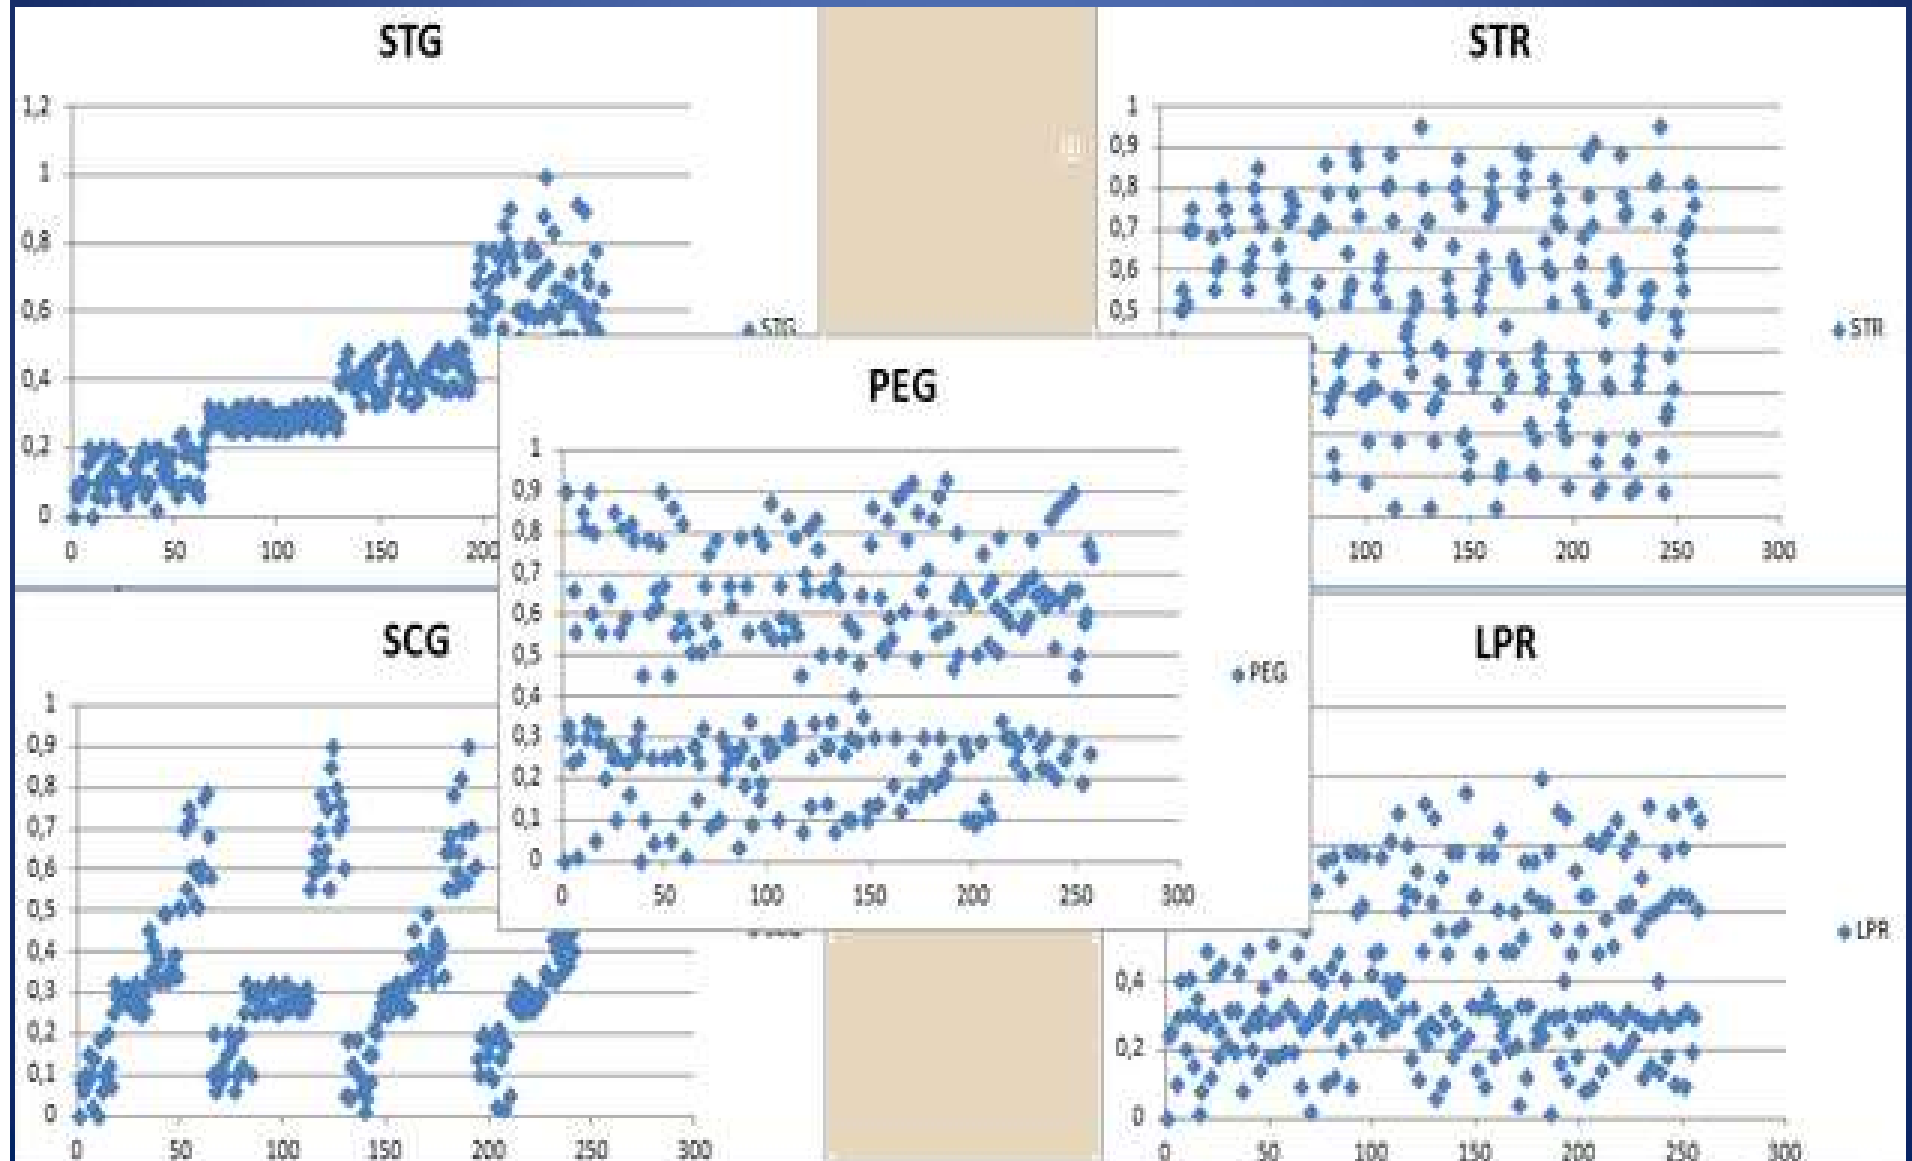
LPR (The exam performance of user for related objects with goal object)

PEG (The exam performance of user for goal objects)






1 variável de saída

Nível de conhecimento do aluno: {(L)ow, (M)edium, (H)igh, (V)ery (H)igh}

Classificação do conhecimento do Usuário





WM: Matching (violeta, vermelho e verde) com a Partição



WM: Tabela de Matching: Ponto x Partição

	STG		SCG			STR		LPR		PEG		
	A	B	A	B	C	A	B	A	B	A	B	C
x' (verde) M	1.0	0.0	0.8	0.2	0.0	0.0	1.0	0.0	1.0	0.7	0.3	0.0
x'' (vermelho) L	1.0	0.0	1.0	0.0	0.0	0.0	1.0	0.5	0.5	0.8	0.2	0.0
x''' (violeta) L	1.0	0.0	1.0	0.0	0.0	0.0	1.0	0.0	1.0	1.0	0.0	0.0



WM: tabela de Matching: Ponto x Partição

	STG		SCG			STR		LPR		PEG		
	A	B	A	B	C	A	B	A	B	A	B	C
x' (verde) M	<u>1.0</u>	0.0	<u>0.8</u>	0.2	0.0	0.0	<u>1.0</u>	0.0	<u>1.0</u>	<u>0.7</u>	0.3	0.0
x'' (vermelho) L	<u>1.0</u>	0.0	<u>1.0</u>	0.0	0.0	0.0	<u>1.0</u>	0.5	<u>0.5</u>	<u>0.8</u>	0.2	0.0
x''' (violeta) L	<u>1.0</u>	0.0	<u>1.0</u>	0.0	0.0	0.0	<u>1.0</u>	0.0	<u>1.0</u>	<u>1.0</u>	0.0	0.0

Valores destacados indicam a maior compatibilidade (maior Matching) dentro da partição de cada variável

WM: Gerando Uma Regra Para Cada Ponto

	STG		SCG			STR		LPR		PEG		
	A	B	A	B	C	A	B	A	B	A	B	C
x' (verde) M	<u>1.0</u>	0.0	<u>0.8</u>	0.2	0.0	0.0	<u>1.0</u>	0.0	<u>1.0</u>	<u>0.7</u>	0.3	0.0
x'' (vermelho) L	<u>1.0</u>	0.0	<u>1.0</u>	0.0	0.0	0.0	<u>1.0</u>	0.5	<u>0.5</u>	<u>0.8</u>	0.2	0.0
x''' (violeta) L	<u>1.0</u>	0.0	<u>1.0</u>	0.0	0.0	0.0	<u>1.0</u>	0.0	<u>1.0</u>	<u>1.0</u>	0.0	0.0

Para x': SE STG=A E SCG=A E STR=B E LPR=B E PEG=A ENTÃO
Classe=Middle

Para x'': SE STG=A E SCG=A E STR=B E LPR=B E PEG=A ENTÃO
Classe=Low

Para x''': SE STG=A E SCG=A E STR=B E LPR=B E PEG=A ENTÃO
Classe=Low

WM: Definindo nível de ativação (μ) da regra

	STG		SCG			STR		LPR		PEG			E=min
	A	B	A	B	C	A	B	A	B	A	B	C	
x' (verde) M	<u>1.0</u>		<u>0.8</u>				<u>1.0</u>		<u>1.0</u>	<u>0.7</u>			$\mu(x') = \min(1, 0.8, 1, 1, 0.7) = 0.7$
x'' (vermelho) L	<u>1.0</u>		<u>1.0</u>				<u>1.0</u>		<u>0.5</u>	<u>0.8</u>			$\mu(x'') = \min(1, 1, 1, 0.5, 0.8) = 0.5$
x''' (violeta) L	<u>1.0</u>		<u>1.0</u>				<u>1.0</u>		<u>1.0</u>	<u>1.0</u>			$\mu(x''') = \min(1, 1, 1, 1, 1) = 1.0$

Para x': SE STG=A E SCG=A E STR=B E LPR=B E PEG=A ENTAO
Classe=Middle ($\mu(x')=0.7$)

Para x'': SE STG=A E SCG=A E STR=B E LPR=B E PEG=A ENTAO
Classe=Low ($\mu(x'')=0.5$)

Para x''': SE STG=A E SCG=A E STR=B E LPR=B E PEG=A ENTAO
Classe=Low ($\mu(x''')=1.0$)


WM: Definindo a regra vencedora (maior μ)

	STG		SCG			STR		LPR		PEG			E=min
	A	B	A	B	C	A	B	A	B	A	B	C	
x' (verde) M	<u>1.0</u>		<u>0.8</u>				<u>1.0</u>		<u>1.0</u>	<u>0.7</u>			$\mu(x')=\min(1,0.8,1,1,0.7)=0.7$
x'' (vermelho) L	<u>1.0</u>		<u>1.0</u>				<u>1.0</u>		<u>0.5</u>	<u>0.8</u>			$\mu(x'')=\min(1,1,1,0.5,0.7)=0.5$
x''' (violeta) L	<u>1.0</u>		<u>1.0</u>				<u>1.0</u>		<u>1.0</u>	<u>1.0</u>			$\mu(x''')=\min(1,1,1,1,1)=1.0$

SE STG=A E SCG=A E STR=B E LPR=B E PEG=A ENTAO Classe=Middle
($\mu(x')=0.7$)

SE STG=A E SCG=A E STR=B E LPR=B E PEG=A ENTAO Classe=Low
($\mu(x'')=0.5$)

SE STG=A E SCG=A E STR=B E LPR=B E PEG=A ENTAO Classe=Low
($\mu(x''')=1.0$)



WM: Repetir o processo para outros pontos

		STG		SCG			STR		LPR		PEG			E=min
		A	B	A	B	C	A	B	A	B	A	B	C	
Xa	VH	0.8				0.8		1.0		1.0	0.8			$\mu(xa)=\min(.8,.8,1,1,0.8)=0.8$
Xb	L	0.7				0.9		0.9		0.5	0.7			$\mu(xb)=\min(.7,.9,.9,.5,0.7)=0.5$
Xc	L	0.8				0.8		0.7		1.0	0.8			$\mu(xc)=\min(.8,.8,.7,1,.8)=0.7$

Para xa: SE STG=A E SCG=C E STR=B E LPR=B E PEG=A ENTAO
Classe=Middle ($\mu(x')=0.8$)

Para xb: SE STG=A E SCG=C E STR=B E LPR=B E PEG=A ENTAO
Classe=Low ($\mu(x'')=0.5$)

Para xc: SE STG=A E SCG=C E STR=B E LPR=B E PEG=A ENTAO
Classe=Low ($\mu(x''')=0.7$)